RKAI 开发指南

文件标识：RK-KF-YF-A61

发布版本：V1.1.0

日期：2026-06-06

文件密级：□绝密 □秘密 □内部资料 ■公开

免责声明

本文档按"现状"提供，瑞芯微电子股份有限公司（"本公司"，下同）不对本文档的任何陈述、信息和内容的准确性、可靠性、完整性、适销性、特定目的性和非侵权性提供任何明示或暗示的声明或保证。本文档仅作为使用指导的参考。

由于产品版本升级或其他原因，本文档将可能在未经任何通知的情况下，不定期进行更新或修改。

商标声明

"Rockchip"、"瑞芯微"、"瑞芯"均为本公司的注册商标，归本公司所有。

本文档可能提及的其他所有注册商标或商标，由其各自拥有者所有。

版权所有 © 2026 瑞芯微电子股份有限公司

超越合理使用范畴，非经本公司书面许可，任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部，并不得以任何形式传播。

瑞芯微电子股份有限公司

Rockchip Electronics Co., Ltd.

地址： 福建省福州市铜盘路软件园A区18号

网址： www.rock-chips.com

客户服务电话： +86-4007-700-590

客户服务传真： +86-591-83951833

客户服务邮箱： fae@rock-chips.com

前言

概述

本文为大语言模型和视觉语言模型的快速验证和开发指南。

产品版本

芯片名称	内核版本
RV1126B	Kernel 6.1
RK3572	Kernel 6.12

读者对象

本文档（本指南）主要适用于以下工程师：

技术支持工程师

软件开发工程师

修订记录

版本号	作者	修改日期	修改说明
V1.0.0	Cherry Chen	2025-09-30	初始版本
V1.1.0	Cherry Chen	2026-06-06	新增 RK3572 支持

目录

- 简介
- RV1126B快速验证
  - LLM快速验证
  - VLM快速验证
- RK3572快速验证
  - LLM快速验证
  - VLM快速验证
- 自定义模型
  - RV1126B 自定义模型配置
  - RK3572 自定义模型配置
- API详细说明
  - LLM API
  - VLM API
  - RK3572 RKNN3新增API

1. 简介

Rockchip AI（RKAI）模块是为 SDK 集成使用大语言模型（Large Language Model, LLM）和视觉语言模型（Vision Language Model, VLM）提供的快速验证模块和适配示例，本模块代码开源，源码路径：`app/rkai`。

RKAI 模块支持两种 NPU 后端：

- **RKLLM 后端**：适用于 RV1126B 芯片，使用 RKNPU2 驱动和 RKLLM 推理库。
- **RKNN3 后端**：适用于 RK3572 芯片，使用 RKNPU3 驱动和 RKNN3 Session 推理接口。

两种后端通过编译宏 `RKAI_DISABLE_RKNN3` 控制：定义该宏时禁用 RKNN3 后端，未定义时在支持的芯片上启用 RKNN3 后端。实际启用状态以对应芯片 SDK 默认配置为准。

目录结构为：

```
tree  rkai -L 1
rkai
├── app_conf # 配置文件和模型文件
├── CMakeLists.txt
├── common  # 通用代码
├── LICENSE
├── rkai_LLM  # LLM模型 API 源码
├── rkai_VLM  # VLM模型 API 源码
└── samples  # 适配用例

5 directories, 2 files
```

- `app_conf` 为通用配置路径，该路径包括模型文件、模型配置文件和模型输入文件三个部分，该部分可以直接集成到板端以供使用；
- `common` 为 RKAI 模块通用代码，例如 `cnpy` 等；
- `rkai_LLM` 为 LLM 部署通用 API；
- `rkai_VLM` 为 VLM 部署通用 API；
- `samples` 提供 LLM/Vision/VLM 三个验证用例。

2. RV1126B快速验证

SDK 默认自动编译了 RKAI 模块，且集成 `Qwen3-0.6B` 模型，供用户快速验证大模型流程。

> **注意**：RK3572 的验证命令见 RK3572快速验证 章节。

2.1 LLM快速验证

LLM 适配程序为 `rkai_LLM_Demo`，用法如下：

```
Usage: rkai_LLM_Demo [options]
Options:
 --llm_model <path>   RKLLM model file
 --config    <path>   Configuration ini file
Example:
 rkai_LLM_Demo --config <path>/rkai_cfg.ini
 rkai_LLM_Demo --config <path>/rkai_cfg.ini --llm_model <your_LLM_model_path>
```

默认推理命令：

```
rkai_LLM_Demo --config <path>/rkai_cfg.ini
```

程序中预置了5个问题，用户可通过数字输入进行选择，也可以终端输入问题。

```
**********************可输入以下问题对应序号获取回答/或自定义输入**********************
[0] 把下面的现代文翻译成文言文: 到了春风和煦，阳光明媚的时候...
[1] 以咏梅为题目，帮我写一首古诗，要求包含梅花、白雪等元素。
[2] 上联: 江边惯看千帆过
[3] 把这句话翻译成中文: Knowledge can be acquired from many sources...
[4] 把这句话翻译成英文: RK3588是新一代高端处理器...

******************************************************************************
```

模型输出为两部分：1、模型回答；2、性能。



也可以自己转换模型后，使用`rkai_LLM_Demo`进行模型推理验证。详细说明见自定义模型章节。

2.2 VLM快速验证

VLM 验证流程由 Vision 和 LLM 两部分组成，可以分开验证，也可以一起进行验证。由于模型内存占用大，不方便集成到 SDK 中。因此，用户可以从以下网址下载模型，以快速验证 VLM 模型。

Vision 模型下载链接为：https://modelscope.cn/models/eliasning/Qwen3-0.6B-w4a16.rv1126b.rkllm/resolve/master/fastvlm-0.5b-fp16.rv1126b.rknn。

LLM 模型下载链接为：https://modelscope.cn/models/eliasning/Qwen3-0.6B-w4a16.rv1126b.rkllm/resolve/master/fastvlm-0.5B-w8a8_level0.rv1126b.rkllm。

仓库名包含 `Qwen3-0.6B`，VLM 文件名使用 FastVLM 0.5B 命名。请按文档中的文件名逐字输入；Linux 路径区分大小写。

将下载的模型推到板端 `app_conf/models` 目录中。然后可以使用 `rkai_VLM_Demo` 进行快速验证。用法如下：

```
Usage: rkai_VLM_Demo [options]
Options:
  --vision_model <path>   Vision RKNN model file
  --llm_model    <path>   LLM RKLLM model file
  --image_path   <path>   Input image file
  --config       <path>   Configuration ini file
Example:
  rkai_VLM_Demo --config <path>/rkai_cfg.ini
  rkai_VLM_Demo --vision_model <path>/fastvlm-0.5b-fp16.rv1126b.rknn \
    --llm_model <path>/fastvlm-0.5B-w8a8_level0.rv1126b.rkllm \
    --image_path <path>/demo.jpg \
    --config <path>/rkai_cfg.ini
```

如果将下载的模型推到`app_conf/models`路径下，则可以使用以下命令推理：

```
rkai_VLM_Demo --config <path>/rkai_cfg.ini
```

如果下载的模型推到其他路径下，则需要手动指定：

```
rkai_VLM_Demo --vision_model xxx.rknn \
          --llm_model xxx.rkllm \
          --image_path <path>/demo.jpg \
          --config <path>/rkai_cfg.ini
```

模型输出为两部分：1、模型回答；2、性能。



3. RK3572快速验证

RK3572 使用 RKNN3 后端，模型格式为 `.rknn` + `.weight` 配套文件。与 RV1126B 的 `.rkllm` 格式不同，RK3572 的 LLM 和 VLM 模型均使用 RKNN3 NPU 接口进行推理。RK3572 SDK 默认不集成下述 LLM/VLM 模型，快速验证前需要用户自行下载模型目录并推送到板端。

RK3572 专用配置文件为 `rkai_cfg_rk3572.ini`，实际文件路径以 SDK 发布包为准。该配置与 RV1126B 配置的主要区别包括 LLM/Vision 模型格式、图像输入格式、`[tensor]` 段的图像占位符格式，以及模型路径和输入路径默认值。

3.1 LLM快速验证

RK3572 的 LLM 模型以模型目录方式传入，目录中需要包含 `.rknn` 模型文件及配套的 `.weight`、`.tokenizer.gguf`、`.embed.bin` 文件。程序会自动从模型目录中检测配套文件。

RK3572 LLM 模型下载链接为：https://modelscope.cn/models/cdd12138/Qwen2.5-0.5B-Instruct。下载仓库中的 `Qwen2.5-0.5B-Instruct-w4a16-1-1024/` 模型目录后，将该目录作为 `--llm_model` 参数传入。

验证命令：

```
rkai_LLM_Demo \
  --config /usr/share/app_conf/config/rkai_cfg_rk3572.ini \
  --llm_model <path>/Qwen2.5-0.5B-Instruct-w4a16-1-1024/
```

模型目录结构示例：

```
Qwen2.5-0.5B-Instruct-w4a16-1-1024/
├── llm.rknn              # LLM模型文件
├── llm.weight            # 权重文件
├── llm.tokenizer.gguf    # 分词器文件
└── llm.embed.bin         # 词嵌入文件
```

输出示例：

```
rkai llm version: 0.0.1
rknn3 session init success

**********可输入以下问题对应序号获取回答/或自定义输入**********
[0] 把下面的现代文翻译成文言文: 到了春风和煦，阳光明媚的时候...
[1] 以咏梅为题目，帮我写一首古诗，要求包含梅花、白雪等元素。
...

user: 0
robot: (模型输出内容)

===== RKNN3_LLM Results Summary =====

TTFT:         xxx.xxx ms
GenLen:       xx tokens
TPS:          xx.xxx tokens/s
Total:        xxx.xxx ms
LLMMemory:    xx.xxx MB

=====================================
```

3.2 VLM快速验证

RK3572 的 VLM 模型以模型目录方式传入，目录中需要包含 Vision 和 LLM 两套 `.rknn` + `.weight` 文件，以及 LLM 配套的 `.tokenizer.gguf` 和 `.embed.bin` 文件。程序会自动从模型目录中检测配套文件。

RK3572 VLM 模型下载链接为：https://modelscope.cn/models/cdd12138/Qwen3-VL-2B-Instruct-384x384。下载仓库中的 `Qwen3-VL-2B-Instruct-384x384-w4a16-1-1024/` 模型目录后，将该目录作为 `--vision_model` 和 `--llm_model` 参数传入。

验证命令：

```
rkai_VLM_Demo \
  --vision_model <path>/Qwen3-VL-2B-Instruct-384x384-w4a16-1-1024/ \
  --llm_model <path>/Qwen3-VL-2B-Instruct-384x384-w4a16-1-1024/ \
  --image_path <path>/Qwen3-VL-2B-Instruct-384x384-w4a16-1-1024/test.jpg \
  --config /usr/share/app_conf/config/rkai_cfg_rk3572.ini
```

模型目录结构示例：

```
Qwen3-VL-2B-Instruct-384x384-w4a16-1-1024/
├── vision.rknn          # Vision模型文件
├── vision.weight        # Vision权重文件
├── llm.rknn             # LLM模型文件
├── llm.weight           # LLM权重文件
├── llm.tokenizer.gguf   # 分词器文件
├── llm.embed.bin        # 词嵌入文件
└── test.jpg             # 测试图片
```

输出示例：

```
rkai vlm version: 0.0.1
vision model: 384x384 ch=3 out_elems=xxxxx
rknn3 vlm llm session init success

**********可输入以下问题对应序号获取回答/或自定义输入**********
[0] <image>What is in the image?
[1] <image>这张图片中有什么元素?
...

user: 0
robot: (模型输出内容)

===== RKNN3_VLM Results Summary =====

VisionCost:    xxx.xxx ms
TTFT:          xxx.xxx ms
GenLen:        xx tokens
TPS:           xx.xxx tokens/s
Total:         xxx.xxx ms
VisionMemory:  xx.xxx MB
LLMMemory:     xx.xxx MB
```

```
TotalMemory:    xx.xxx MB

===================================
```

4. 自定义模型

4.1 RV1126B 自定义模型配置

RV1126B 使用 `rknn-llm` 进行模型转换，工具下载链接：https://github.com/airockchip/rknn-llm。用户可以自行转换模型，通过 `rkai_LLM_Demo` 和 `rkai_VLM_Demo` 进行推理。用户自定义模型时，`rkai_cfg.ini` 需要进行对应修改。

1. `rkai_cfg.ini` 中 `[llm_cfg]` 为 LLM 参数，包含模型超参数，用户可以通过调节参数来调整模型。参数如下：

参数	默认值	说明
llm_model	models/Qwen3-0.6B_W4A16_RV1126B.rkllm	可以通过外部参数 `--llm_model` 定义
max_context_len	1024	最长上下文
max_new_tokens	128	最长输出tokens
skip_special_token	1	是否跳过特殊字符
base_domain_id	0	NPU内存域ID，默认为0
top_k	1	大于等于1

2. `rkai_cfg.ini` 中 `[vlm_cfg]` 为 VLM 参数，包含模型超参数，用户可以通过调节参数来调整模型。参数如下：

参数	默认值	说明
vision_model	models/fastvlm-0.5b-fp16.rv1126b.rknn	可以通过外部参数 `--vision_model` 定义
llm_model	models/fastvlm-0.5B-w8a8_level0.rv1126b.rkllm	可以通过外部参数 `--llm_model` 定义
image_path	inputs/image_1024x1024.npy	支持输入 jpg 图片，通过 `--image_path` 指定
max_context_len	512	最长上下文
max_new_tokens	128	最长输出tokens
skip_special_token	1	是否跳过特殊字符
base_domain_id	0	NPU内存域ID，默认为0
top_k	1	大于等于1

3. `rkai_cfg.ini` 中 `[prompt]` 为系统 prompt，用户自定义模型时，这部分需要修改。参数如下：

参数	默认值	说明
system_prompt	<|im_start|>system\nYou are a helpful assistant. <|im_end|>\n	默认为 Qwen3 的系统 prompt
prompt_prefix	<|im_start|>user\n	通过模型的 config 文件可以获取
prompt_postfix	<|im_end|>\n<|im_start|>assistant\n	通过模型的 config 文件可以获取

4. `rkai_cfg.ini` 中 `[tensor]` 为 VLM 模型的图像占位符，用户自定义模型时，这部分需要修改。参数如下：

参数	默认值	说明
img_start	<|im_start|>	图像占位符，可以在模型config中获取
img_end	<|im_end|>	同上
img_content	<|im_content|>	同上

4.2 RK3572 自定义模型配置

RK3572 使用 `rknn3-toolkit` 进行模型转换，工具下载链接：https://github.com/airockchip/rknn3-toolkit。

RK3572 使用 `rkai_cfg_rk3572.ini`，与 RV1126B 的 `rkai_cfg.ini` 有以下差异：

1. **LLM模型文件**：RK3572 的 LLM 模型需要 `.rknn`、`.weight`、`.tokenizer.gguf`、`.embed.bin` 四个文件配套使用（RV1126B 仅需 `.rkllm`）。
2. **VLM Vision模型文件**：RK3572 的 Vision 模型需要 `.rknn` 和 `.weight` 两个文件（RV1126B 仅需 `.rknn`）。
3. **图像占位符**：RK3572 配合 Qwen3-VL 模型时，默认图像占位符为：

参数	默认值	说明
img_start	<|vision_start|>	图像占位符，可以在模型config中获取
img_end	<|vision_end|>	同上
img_content	<|image_pad|>	同上

4. **图像输入格式**：RK3572 典型验证流程通过 `--image_path` 传入 `.jpg` 图片，由程序内置 JPEG 解码流程处理。
5. **模型路径和输入路径**：`vision_model`、`llm_model`、`image_path` 在 `rkai_cfg_rk3572.ini` 中默认为 `none`，通常通过命令行参数 `--vision_model`、`--llm_model`、`--image_path` 传入。其中 `--vision_model` 和 `--llm_model` 传入模型目录，而不是单个 `.rknn` 文件。

RK3572 配置示例：

```
[vlm_cfg]
vision_model=none
llm_model=none
image_path=none

[tensor]
img_start=<|vision_start|>
img_end=<|vision_end|>
img_content=<|image_pad|>
```

5. API详细说明

用户可以自行调用API进行应用集成，API全开源，以下是API说明。

5.1 LLM API

对LLM模型进行初始化和反初始化的API如下：

API	**rkai_llm_init**
描述	LLM初始化
参数	rkaiCtxLLM *ctx：LLM句柄
	rkaiCfg *cfg：LLM参数配置
返回	int，0表示成功，非0表示失败

API	**rkai_llm_release**
描述	LLM反初始化
参数	rkaiCtxLLM *ctx：LLM句柄
返回	void

对LLM推理部署的API如下：

API	**rkai_llm_run**
描述	LLM推理
参数	rkaiCtxLLM *ctx：LLM句柄
	rkaiCfg *cfg：LLM参数配置
返回	int，0表示成功，非0表示失败

API	rkai_llm_query_memory
描述	查询LLM模型占用NPU内存
参数	rkaiCtxLLM *ctx：LLM句柄
返回	int64_t 内存字节数

5.2 VLM API

5.2.1 VLM的Vision模型API

API	rkai_vlm_vision_init
描述	Vision初始化，仅适用于 RV1126B/RKNPU2 后端
参数	const char *model_path：Vision模型路径，为 `.rknn` 模型
	rkaiCtxVision *ctx：Vision句柄
返回	int，0表示成功，非0表示失败

API	rkai_vlm_vision_release
描述	Vision反初始化
参数	rkaiCtxVision *ctx：Vision句柄
返回	int，0表示成功，非0表示失败

对Vision推理的API如下：

API	rkai_vlm_vision_run
描述	Vision推理
参数	rkaiCtxVision *ctx：Vision句柄
	void *img_data：输入图片buffer，格式为RGB888
	rkaiVisionToLLM *vtol：Vision到LLM的传递参数和buffer
返回	int，0表示成功，非0表示失败

5.2.2 VLM的LLM API

API	rkai_vlm_llm_init
描述	LLM初始化
参数	rkaiCtxVLM *ctx：VLM句柄
	rkaiVLMCfg cfg：VLM参数配置
返回	int，0表示成功，非0表示失败

API	rkai_vlm_llm_release
描述	LLM反初始化
参数	rkaiCtxVLM *ctx：VLM句柄
返回	int，0表示成功，非0表示失败

对LLM推理部署的API如下：

API	rkai_vlm_llm_run
描述	LLM推理
参数	rkaiCtxVLM *ctx：VLM句柄
	rkaiVLMCfg cfg：VLM参数配置
	rkaiVisionToLLM *vtol：从 Vision 接收的传递参数
返回	int，0表示成功，非0表示失败

API	rkai_vlm_llm_query_memory
描述	查询VLM LLM模型占用NPU内存
参数	rkaiCtxVLM *ctx：VLM LLM句柄
返回	int64_t 内存字节数

5.3 RK3572 RKNN3新增API

RK3572 使用 RKNN3 后端时，LLM 仍使用上述通用 LLM 及 VLM LLM API；Vision 部分使用以下 RKNN3 专用 API：

Vision RKNN3 API：

API	rkai_vlm_vision_init_rknn3
描述	Vision RKNN3初始化
参数	const char *model_path：Vision `.rknn`模型路径
	const char *weight_path：Vision `.weight`权重路径
	rkaiCtxVisionRknn3 *ctx：Vision句柄
	uint32_t core_mask：NPU核心掩码，0表示自动检测
返回	int，0表示成功，非0表示失败

API	rkai_vlm_vision_run_rknn3
描述	Vision RKNN3推理（内置resize和normalize）
参数	rkaiCtxVisionRknn3 *ctx：Vision句柄
	unsigned char *img_data：输入图片RGB888数据
	int img_width：输入图片宽度
	int img_height：输入图片高度
	rkaiVisionToLLM *vtol：Vision到LLM的传递参数
返回	int，0表示成功，非0表示失败

API	rkai_vlm_vision_release_rknn3
描述	Vision RKNN3反初始化
参数	rkaiCtxVisionRknn3 *ctx：Vision句柄
返回	int，0表示成功，非0表示失败

API	rkai_vlm_vision_query_memory_rknn3
描述	查询Vision模型占用NPU内存
参数	rkaiCtxVisionRknn3 *ctx：Vision句柄
返回	int64_t 内存字节数